Identificação e incorporação de relações para migração de dispositivos entre data centers.

Fábio de Oliveira Francisco[1]*; Rafael Henrique Roque[2]

[1] Santander Serviços Digitais. IT Engineer Expert.
[2] USP/Esalq Doutor em Recursos Florestais.

Identificação e incorporação de relações para migração de dispositivos entre data centers

Resumo

O avanço das tecnologias de virtualização, computação em nuvem e edge computing intensificou a necessidade de migração de dispositivos entre data centers, tornando esse processo estratégico para a garantia da disponibilidade, escalabilidade e eficiência operacional. Contudo, a migração envolve elevada complexidade técnica, especialmente em razão das múltiplas interdependências entre os dispositivos de infraestrutura. A desconsideração dessas relações pode resultar em falhas, indisponibilidade de serviços e perdas de desempenho. Diante desse cenário, este trabalho propôs a utilização da Análise de Redes Sociais (Social Network Analysis – SNA) como metodologia para a identificação e incorporação das relações de dependência entre dispositivos no planejamento de migrações de servidores entre data centers. A infraestrutura foi modelada como uma rede composta por nós e conexões, possibilitou a aplicação de métricas de SNA, como centralidade, intermediação, proximidade, densidade e modularidade. Essas métricas permitiram identificar dispositivos críticos, vulnerabilidade e agrupamentos, fornecendo subsídios relevantes para a tomada de decisão. O trabalho foi desenvolvido por meio da identificação das relações entre dispositivos a partir de dados de rede, da construção de uma matriz de adjacência e do cálculo das métricas de SNA. Para a análise e validação do modelo proposto, foram utilizados os algoritmos Louvain, Random Forest Classifier e Graph Convolutional Network (GCN). O modelo sugeriu a migração prioritária de dispositivos periféricos, a postergação de nós com elevada centralidade de intermediação e a migração conjunta de clusters fortemente conectados. Os resultados indicaram que a SNA contribuiu para migrações mais seguras, estruturadas e eficientes, reduzindo riscos operacionais, e o tempo de planejamento.

Palavras-chave: Infraestrutura digital; Dependências sistêmicas; Planejamento de transição; Topologia computacional; Continuidade operacional.

Identifying and incorporating relationships for migrating devices between data centers.

Abstract

The advancement of virtualization, cloud computing, and edge computing technologies has intensified the need for device migration between data centers, making this process strategic for ensuring availability, scalability, and operational efficiency. However, migration involves high technical complexity, especially due to the multiple interdependencies between infrastructure devices. Disregarding these relationships can result in failures, service unavailability, and performance losses. In this context, this work proposed the use of Social Network Analysis (SNA) as a methodology for identifying and incorporating dependency relationships between devices in the planning of server migrations between data centers. The infrastructure was modeled as a network composed of nodes and connections, enabling the application of SNA metrics such as centrality, betweenness, proximity, density, and modularity. These metrics allowed the identification of critical devices, vulnerabilities, and clusters, providing relevant support for decision-making. The work was developed through the identification of relationships between devices from network data, the construction of an adjacent matrix, and the calculation of SNA metrics. For the analysis and validation of the proposed model, the Louvain, Random Forest Classifier, and Graph Convolutional Network (GCN) algorithms were used. The model suggested prioritizing the migration of peripheral devices, postponing nodes with high betweenness centrality, and migrating strongly connected clusters together. The results indicated that SNA contributed to safer, more structured, and efficient migrations, reducing operational risks and planning time.

Keywords: Digital infrastructure; System dependencies; Transition planning; Computational topology; Operational continuity.

Introdução

Com o crescimento exponencial dos dados e a demanda por maior eficiência e agilidade, a migração de servidores de um data center para outro se tornou uma tarefa complexa e desafiadora. O processo envolve diversas etapas críticas, desde o planejamento inicial até a execução e validação pós-migração. Tradicionalmente, essa empreitada exige um esforço manual intenso, análise de dados complexa e, muitas vezes, a chance de erros humanos, que podem resultar em tempo de inatividade prolongado e custos elevados.

A análise de grafos tem emergido como uma ferramenta fundamental para desvendar a estrutura subjacente e o comportamento de sistemas complexos em diversas áreas, desde redes sociais e biológicas até infraestruturas de TI e comunicação. Em um cenário onde a conectividade e a interdependência entre entidades são cada vez mais proeminentes, a capacidade de modelar e analisar essas relações é crucial. Este trabalho foca na aplicação de técnicas de Machine Learning (ML) em grafos para extrair insights valiosos de dados de conexão, utilizando um conjunto de dados representativo de dispositivos e suas interações (pcluster.xlsx).

O principal objetivo foi demonstrar como o Machine Learning pode ser empregado para entender a topologia da rede, identificar padrões de agrupamento e prever conexões futuras, bem como avaliar a robustez e a vulnerabilidade da rede. Especificamente, os objetivos podem ser detalhados como:

Identificação de Subgrupos (Comunidades ou clusters): Dividir a rede em subgrupos coesos, ou comunidades, onde os nós dentro de um grupo estão mais densamente conectados entre si do que com os nós de outros grupos. Isso permitiu uma compreensão modular da rede.

Previsão de Ligações, foi desenvolvido modelo capaz de prever a existência de ligações entre pares de nós, uma tarefa crítica para recomendação de produtos, detecção de anomalias ou completude de dados.

Análise de Robustez e Vulnerabilidade, foi avaliado como a rede se comportou sob condições de falha, seja por remoção aleatória de nós/arestas ou por ataques direcionados a elementos críticos (Hubs), quantificando o impacto na conectividade.

Caracterização de Nós e Arestas Críticas, foram identificados nós e arestas que desempenharam papéis cruciais na conectividade e no fluxo de informação da rede, utilizando métricas de centralidade.

Nesse contexto para o mercado operacional de TI (Tecnologia da informação), o objetivo desta pesquisa propôs a utilização da Análise de Redes Sociais (Social Network Analysis – SNA) como metodologia para identificar e incorporar relações de dependência entre dispositivos durante o planejamento de migrações entre data centers. A SNA possibilitou modelar a infraestrutura como uma rede composta por nós e conexões, permitindo a aplicação de métricas como centralidade, intermediação, proximidade, densidade e modularidade. Essas métricas viabilizaram a identificação de dispositivos críticos, pontos de vulnerabilidade e agrupamentos fortemente interconectados, fundamentais para a tomada de decisão.

A relevância deste trabalho reside, portanto, em contribuir para a literatura e para a prática empresarial ao demonstrar, a partir de um caso real, como a aplicação de ferramentas de criação e análise de grafo, análise de rede socias (SNA), machine learning e rede neural e de técnicas de inteligência artificial pode gerar “insights” valiosos para o planejamento mais eficiente na migração de dispositivos entre Data centers. Ao analisar os dados o modelo sugeriu a migração prioritária de dispositivos periféricos, a postergação de nós com elevada centralidade de intermediação e a migração conjunta de clusters fortemente conectados. Os resultados indicaram que a SNA contribuiu para migrações mais seguras, estruturadas e eficientes, reduzindo riscos operacionais, e o tempo de planejamento.

Material e Métodos

A pesquisa caracterizou-se como aplicada, quantitativa e exploratória, sendo conduzida por meio de revisão bibliográfica e estudo de caso e simulação controlada. O método incluiu a identificação das relações entre dispositivos a partir de dados de rede, a construção de uma matriz de adjacência, o cálculo das métricas de SNA e a proposição de um modelo de apoio à migração.

Como resultado esperado, buscou-se demonstrar que a incorporação da SNA contribuiu para migrações mais seguras, estruturadas e eficientes, reduzindo riscos operacionais, interrupções de serviços e o tempo total de planejamento.

Algoritmos e Métodos Propostos: Finalidade e Classificação

Para atingir esses objetivos, diversos algoritmos e técnicas de Machine Learning e Teoria dos Grafos foram empregados, cada um com uma finalidade específica.

Criação/Detecção de Comunidades (Análise Não Supervisionada) Algoritmo de Louvain

Foi iniciado com uma abordagem de aprendizado não supervisionado utilizando o Algoritmo de Louvain. O objetivo foi otimizar a modularidade da rede para identificar agrupamentos ou comunidades nativas de dispositivos dentro da infraestrutura.

Método Louvain (Louvain Method), algoritmo heurístico para detecção de comunidades em redes grandes, que otimiza a modularidade (Medida da força da divisão de uma rede em módulos). É um método de aprendizado não supervisionado amplamente utilizado pela sua eficiência e capacidade de identificar estruturas hierárquicas de comunidades (Blondel et al., 2008). Sua finalidade é particionar o grafo em subgrupos, revelando a estrutura modular da rede sem a necessidade de rótulos pré-definidos.

Previsão de Ligações (Análise Supervisionada e Deep Learning) com Algoritmo Randon Forest

O Random Forest, é um modelo de aprendizado supervisionado. Foi utilizado essa técnica tradicional para a predição de conexões entre os dispositivos, avaliando o comportamento das ligações na rede.

Random Forest Classifier, algoritmo de aprendizado supervisionado e de ensemble modeling (modelagem de conjunto), que constrói múltiplas árvores de decisão durante o treinamento e produz a classe que é a moda das classes (Classificação) ou a previsão média (Regressão) das árvores individuais (Breiman, 2001). Neste contexto, foi utilizado para prever a existência de ligações com base em features clássicas de grafo (e.g., Adamic-Adar, Jaccard, Preferential Attachment). Sua finalidade foi classificar pares de nós como conectados ou não conectados.

Deep Learning com GCN (Graph Convolutional Network)

Para elevar o nível de análise estrutural, foi incorporado o Deep Learning aplicado a Grafos através de GCN. A GCN permitiu trabalhar com embeddings de nós e realizar a predição de ligações considerando tanto os atributos dos dispositivos quanto a topologia complexa da rede.

Graph Convolutional Network (GCN), é a forma de Deep Learning especificamente projetada para dados de grafos. As GCNs aprendem embeddings (Representações vetoriais) de nós agregando informações dos vizinhos, o que as torna poderosas para tarefas como classificação de nós e previsão de ligações (Kipf & Welling, 2017). A previsão de ligações é realizada via produto interno dos embeddings dos nós, sendo uma abordagem de aprendizado supervisionado (ou semi-supervisionado, dependendo da tarefa). Neste

contexto a finalidade foi aprender representações de nós que capturam a estrutura do grafo e as características dos nós para prever conexões.

Análise de Grafo utilizando Métricas de SNA para comunidades (Análise Não Supervisionada/Métricas Descritivas)

Para interpretar esses grafos, foram utilizadas duas métricas principais de SNA, sendo a centralidade de grau, para identificar os nós considerados hubs (Dispositivos centrais ou com grande volume de conexões) e a centralidade de intermediação, para identificar as pontes na rede, medindo o grau de influência e a criticidade dessas conexões para o fluxo de dados.

Centralidade de Grau (Degree Centrality), mediu o número de conexões diretas de um nó. Usada para identificar nós 'hub', que são importantes pela sua alta conectividade (Freeman, 1978). Classificado como análise não supervisionada/descritiva.

Centralidade de Intermediação (Betweenness Centrality), qualificou o número de vezes que um nó (ou uma aresta) agiu como uma ponte.

Coleta de dados, estruturação das informações e ferramentas utilizadas

Todos os dados analisados foram extraídos diretamente dos sistemas utilizados pela empresa, por meio de relatórios exportados em formato CSV, XLSX e integrações nativas das plataformas. Para coleta dos dados foi utilizada uma ferramenta denominada Device42, durante um período de 30 dias foram coletados relatórios com informações técnicas sobre comunicação de serviços entre dispositivos (Listening device, Listening IP, Listening service, Listening port, Port communication, Protocol, Client device, Cliente IP, Netstat time). Foram extraídas tabelas contendo séries históricas sobre as informações técnica dos servidores na rede da empresa.

Todos os arquivos gerados foram consolidados em uma planilha no Microsoft Excel, nas quais se realizou a padronização das bases, a anonimização dos registros e a criação de Trabalho de Conclusão de Curso apresentado para obtenção do título de especialista em Data Science and Analytics – 2026.

Foi criado um arquivo em Excel “pcluster.xlsx”, utilizado como dataset para a extração de todos os dados.

Dessa forma, foi possível realizar uma análise técnica da interconexão entre os dispositivos, entendida como o monitoramento das mesmas variáveis ao longo de um intervalo de tempo de 30 dias, o que permitiu identificar tendências, sobre os dispositivos de

centralidade e intermediação, dispositivos periféricos, comunidades ou grupos (Clusters) de dispositivos fortemente conectados.

A empresa analisada que, por questões de confidencialidade, será denominada BanFF, é uma empresa multinacional no setor de serviços bancários de grande porte sediada na cidade do México, especializada em bancos corporativos, institucionais e de varejo. Seu modelo de negócios é baseado em serviços de gestão de liquidez, fundos de investimento e seguros. A operação está presente em 64 países.

Para a análise de dados, foi utilizada a estrutura da metodologia de SNA seguindo as seguintes etapas:

Coleta de dados: extração de iterações (Quantidade de iterações entre os dispositivos por meio de protocolo de comunicação SNMP - Simple Network Management Protocol)

Preparação dos dados: Estruturação dos dados em formatos de nós (Servidores) e arestas (Conexões/relações) entre os servidores.

Visualização: Criação de grafos utilizando algoritmos para visualizar a proximidade e o agrupamento dos dispositivos.

Análise de métricas: Aplicação de indicadores quantitativos para estrutura e influência.

Complementarmente a metodologia, foram extraídos “insights”, utilização de inteligência artificial, cruzamento de dados. A ferramenta de linguagem natural Google Gemini ajudou no entendimento preliminar de informações e construção textual.

As ferramentas utilizadas para codificação análise e tratamento de dados, foram Python e Microsoft Excel. Segue as bibliotecas utilizadas no Python:

Pandas, Numpy, NetoworkX, scikit-learn, matplotlib.pyplot, seaborn, torch, community.community_louvain, scipy.sparse.

A análise foi baseada em dados secundários registrados através de dados coletados das plataformas de hypervisor da empresa. A pesquisa não incluiu a realização de análises primárias com consumidores. O foco foi inteiramente nos dados sistêmicos trafegados na rede local por meio de serviços de comunicação. A pesquisa foi realizada na cidade de São Paulo, estado de São Paulo, com base em dados operacionais da rede da empresa no México.

Construção do Grafo

O objetivo do código foi transformar uma tabela de comunicações de rede (linhas com origem, destino, porta, protocolo e serviço) em um grafo, que pudesse ser usado por uma Rede Neural de Grafos (GNN). Neste caso os dispositivos foram utilizados como nós, os protocolos de comunicações viraram arestas e as informações de comunicações viraram os atributos das arestas.

Mapeamento dos Nós

Os nós foram obtidos a partir das colunas *source* e *target* do conjunto de dados. Formalmente, define-se:

O conjunto de nós foi definido conforme a eq. (1):

$$V = \{v_i \mid v_i \in \text{source} \cup \text{target}\} \quad (1)$$

Cada nó v ∈ V foi mapeado para um identificador inteiro único por meio da função apresentada na eq. (2):

$$f: V \to \mathbb{N}, f(v_i) = i \quad (2)$$

Em que f representa a função de mapeamento e |V| corresponde à quantidade total de nós.

Representação das Arestas

Cada aresta foi definida como um par ordenado, conforme a eq. (3):

$$e_k = (v_s, v_t) \in E \quad (3)$$

Onde v_sé o nó de origem e v_to nó de destino.

A estrutura de conectividade do grafo foi representada pelo tensor apresentado na eq. (4):

$$\mathbf{E} = \begin{bmatrix} f(v_{s_1}) & f(v_{s_2}) & \cdots & f(v_{s_E}) \\ f(v_{t_1}) & f(v_{t_2}) & \cdots & f(v_{t_E}) \end{bmatrix} \quad (4)$$

Em que $\mathbf{E}$ é o número total de arestas. Essa matriz corresponde ao edge_index utilizado pelo PyTorch Geometric.

Codificação dos Atributos das Arestas

Cada aresta e possuiu um vetor de atributos, conforme a eq. (5):

$$\mathbf{a}_k = [p_k, r_k, s_k] \quad (5)$$

Em que:

$p_k$representa a porta de comunicação,

$r_k$representa o protocolo,

$s_k$representa o serviço associado.

Resultados e Discussão

Resultados sobre treinamento do modelo, identificação dos nós e arestas, identificação de comunidades, identificação de hubs, pontes e visualização de grafos.

A GNN (Graph Convolutional Network) aprendeu representações vetoriais dos nós a partir da estrutura do grafo e de seus atributos. Em seguida, uma função de pontuação estimou a probabilidade de existência de uma ligação entre pares de nós, permitindo a identificação de conexões prováveis ou anômalas**.**

Em um grafo $G = (V, E)$, a previsão de ligações consistiu em estimar a probabilidade de existir uma aresta entre dois nós que ainda não estavam conectados.

Formalmente, dado um par de nós $(u, v) \in V \times V$ o objetivo foi estimar a probabilidade indicada na eq. (6):

$$P((u, v) \in E \mid G) \quad (6)$$

Número de nós: 142

Arestas de treinamento (incluindo negativas): 1206

Arestas de validação (incluindo negativas): 170

Arestas de teste (incluindo negativas): 342

Foi realizado um treinamento com 10 épocas:

Época: 010, Perda (Loss): 0.5478, AUC de Validação: 0.8790

Época: 020, Perda (Loss): 0.4394, AUC de Validação: 0.8472

Época: 030, Perda (Loss): 0.3850, AUC de Validação: 0.8505

Época: 040, Perda (Loss): 0.3501, AUC de Validação: 0.8389

Época: 050, Perda (Loss): 0.3174, AUC de Validação: 0.8292

Época: 060, Perda (Loss): 0.3057, AUC de Validação: 0.8264

Época: 070, Perda (Loss): 0.2678, AUC de Validação: 0.8198

Época: 080, Perda (Loss): 0.2699, AUC de Validação: 0.8109

Época: 090, Perda (Loss): 0.2276, AUC de Validação: 0.8248

Época: 100, Perda (Loss): 0.2392, AUC de Validação: 0.7950

AUC no conjunto de teste: 0.8444

A figura 1, apresentou os resultados quantitativos da GNN (Graph Neural Network) na tarefa de predição de ligações (Link Prediction), provando a acurácia do modelo através da métrica AUC (0,8444) e do histórico de treinamento/perda.

Para esta validação, foi criado uma sub-rede contendo 142 nós (Dispositivos / Servidores) e 404 arestas (conexões mapeadas).

Foi verificado uma redução consistente da função de perda (Loss), que caiu de 0,54 na época 10 para 0,23 na época 100, demonstrando que a rede aprendeu os padrões topológicos sem sofrer de instabilidade.

E no conjunto de teste, o modelo alcançou um valor final de AUC de 0,8444.

De acordo com o gráfico da Curva ROC à esquerda, a linha laranja representou a performance do modelo, enquanto a linha pontilhada azul representou um classificador aleatório.

O valor de AUC de 0,84 (84,4%) confirmou que a GNN possuiu uma excelente capacidade de discriminação. Ou seja, ela conseguiu distinguir com alta precisão entre ligações reais que existem na infraestrutura e conexões inexistentes.

Em termos práticos e de negócio, este resultado demonstrou que o modelo atribuiu, com elevada probabilidade, pontuações significativamente maiores para conexões reais. Isso validou o uso de Deep Learning em Grafos como uma ferramenta altamente confiável para prever dependências ocultas e guiar o planejamento de migrações em ambientes corporativos.

A taxa de verdadeiros positivos (True Positive Rate – TPR) representou a proporção de ligações existentes corretamente identificadas pelo modelo, sendo definida pela eq. (7):

$$\mathrm{TPR} = \frac{\mathrm{TP}}{\mathrm{TP+FN}} \qquad (7)$$

Por sua vez, a taxa de falsos positivos (False Positive Rate – FPR) indicou a proporção de ligações inexistentes que foram incorretamente classificadas como existentes, conforme a eq. (8):

$$\mathrm{FPR} = \frac{\mathrm{FP}}{\mathrm{FP+TN}} \qquad (8)$$

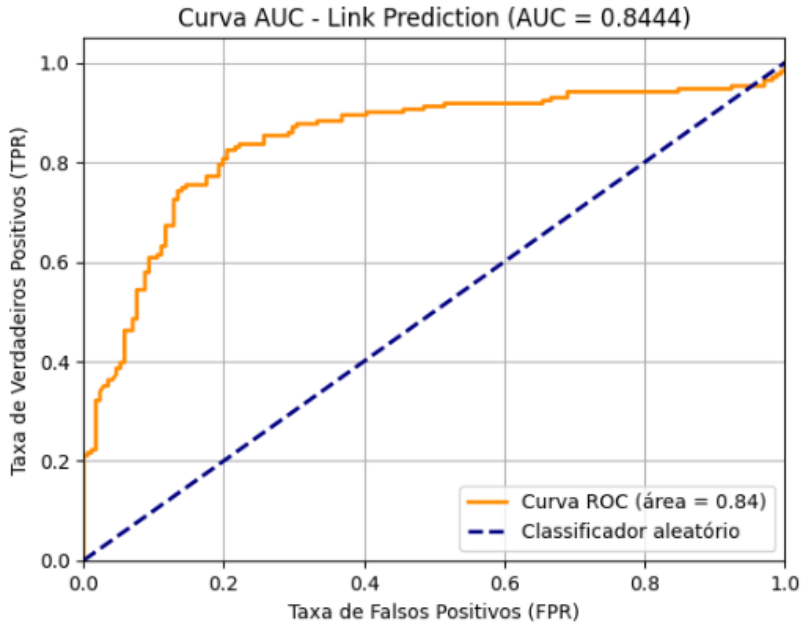


Figura 1. Curva ROC do modelo GNN para previsão de ligações

Fonte: Dados originais da pesquisa

A figura 2, representou o grafo criado com 142 nós e 404 arestas que foi criado pelo modelo treinado (GNN) utilizando o algoritmo de Louvain.

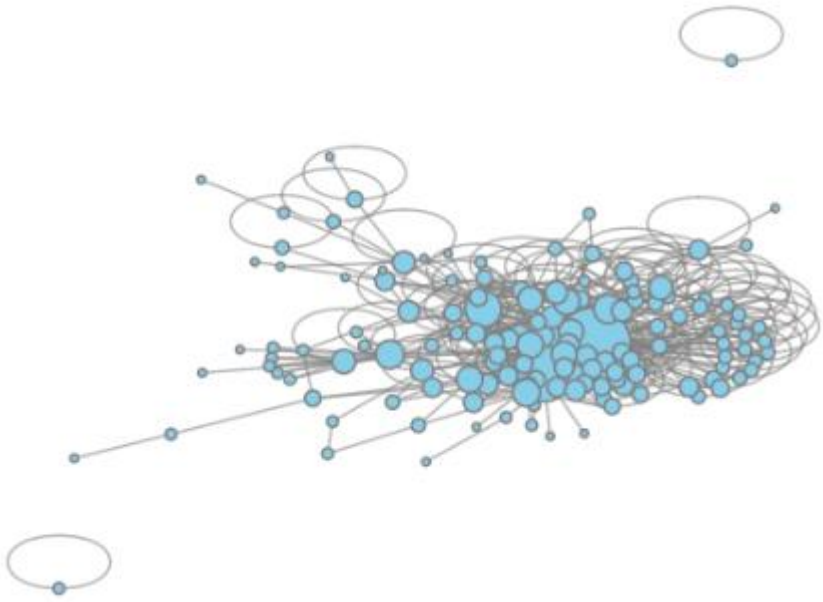


Figura 2. Grafo com 142 nós e 404 arestas.

Fonte: Dados originais da pesquisa.

Algoritmo de Agrupamento Louvain

O algoritmo de Louvain é um método amplamente utilizado para detecção de comunidades em grafos, cujo objetivo principal é identificar subconjuntos de nós que apresentam maior densidade de conexões internas quando comparados às conexões com nós externos. Esse algoritmo destaca-se por sua eficiência computacional e por sua capacidade de lidar com grafos de grande escala.

Em um grafo $G = (V, E)$, uma comunidade pode ser definida como um conjunto de nós C que as conexões entre os nós de C são mais frequentes ou mais fortes do que as conexões de nós pertencentes a outros conjuntos. A identificação dessas estruturas permitiu compreender padrões de organização e comportamento em redes complexas.

O algoritmo de Louvain baseia-se na maximização da modularidade, métrica que avalia a qualidade de uma divisão do grafo em comunidades. A modularidade Q é definida pela eq. (9):

$$Q = \frac{1}{2m}\sum_{i,j}\left(A_{ij} - \frac{k_i k_j}{2m}\right)\delta(c_i, c_j) \qquad (9)$$

Em que:

A_{ij}representa a matriz de adjacência do grafo;

k_ie $k_j$correspondem aos graus dos nós ie j;

mé o número total de arestas do grafo;

$c_i$indica a comunidade à qual o nó $i$pertence;

$\delta(c_i, c_j)$é a função delta de Kronecker, que assume valor 1 quando $c_i = c_j$e 0 caso contrário.

Valores mais elevados de Q indicam uma estrutura de comunidades mais bem definida.

A tabela 1, apresentou a atribuição das comunidades (Clusters), gerados pelo algoritmo de Louvain para os dez primeiros nós do grafo analisado. Cada linha indicou um nó da rede e o identificador da comunidade à qual esse nó foi associado após a maximização da modularidade.

O identificador da comunidade correspondeu a um rótulo numérico atribuído automaticamente pelo algoritmo e não possuiu significado ordinal ou hierárquico. Assim, valores distintos indicaram apenas que os nós pertencem a comunidades diferentes.

Observou-se que alguns nós foram agrupados na mesma comunidade, indicando que apresentaram padrões de conectividade semelhantes dentro da rede. Por exemplo, os nós FF.X.186.68, FFXL07100022VM e photon-machine foram atribuídos a comunidade 0, o que

sugere que esses dispositivos mantiveram maior densidade de conexões entre si ou com um mesmo conjunto de vizinhos, quando comparados ao restante do grafo.

De forma análoga, os nós FFXS07100025MIG, FFXS07100086VM e FFXS071000351VM pertenceram a comunidade 1, indicando a formação de outra comunidade distinta, possivelmente relacionada a um mesmo tipo de serviço, função ou comportamento de comunicação na rede.

Os nós FFXSL7100017 e FFXS07100085 foram agrupados na comunidade 2, enquanto FFXS075000181 e FFXS07100011Clo compuseram a comunidade 3, evidenciando a existência de múltiplas comunidades com características próprias.

Os resultados obtidos por meio do algoritmo de Louvain evidenciaram a presença de uma estrutura comunitária bem definida no grafo analisado. A identificação dessas comunidades contribuiu para uma melhor compreensão da organização da rede, permitindo a identificação de padrões sobre o comportamento das interações entre os dispositivos.

Tabela 1 - Clusters

Nós	Comunidade
FF.X.186.68	0
FFXL07100022VM	0
FFXS07100025MIG	1
FFXS07100086VM	1
FFXSL7100017	2
FFXS07100085	2
FFXS075000181	3
FFXS07100011Clo	3
FFXS071000351VM	1
photon-machine	0

Fonte: Resultados originais da pesquisa

Visualização do Grafo com Comunidades (clusters Louvain)

A figura 3, ilustrou a visualização do grafo cujos nós estão coloridos conforme a atribuição das comunidades detectadas pelo algoritmo de Louvain. Cada cor representou uma comunidade distinta, ou seja, um conjunto de nós com maior densidade de conexões internas em relação às conexões externas.

Observou-se a formação de múltiplas comunidades, evidenciando a modularidade presente na estrutura da rede. Foi destacado a presença de um nó central, com alto grau de conexão, que atuou como um hub, conectando diversas comunidades distintas. Esse ponto central representou um elemento-chave na rede, influenciando o fluxo de informações ou interações entre os grupos.

As comunidades apresentaram variações em seu tamanho e densidade. Algumas são compactas e altamente conectadas, sugerindo agrupamentos coesos de nós com intensa interação mútua. Outras comunidades são menores e mais dispersas, possivelmente correspondendo a subgrupos ou nós periféricos, com menor grau de conexão interna.

Além disso, foi possível identificar pequenos clusters afastados do núcleo principal da rede, o que pode indicar a existência de comunidades isoladas ou nós com conexões limitadas.

A detecção dessas comunidades foi fundamental para compreender a organização estrutural da rede, permitindo segmentar a análise em grupos mais homogêneos. Essa segmentação possibilitou, por exemplo, a identificação de subgrupos funcionais, domínios administrativos ou áreas de maior vulnerabilidade dentro do sistema analisado.

Por fim, ressalta-se que a disposição visual dos nós influencia a percepção da estrutura comunitária, sendo recomendada a complementação da análise com métricas quantitativas, tais como modularidade, tamanho médio das comunidades e grau médio dos nós, para uma avaliação mais detalhada da rede.

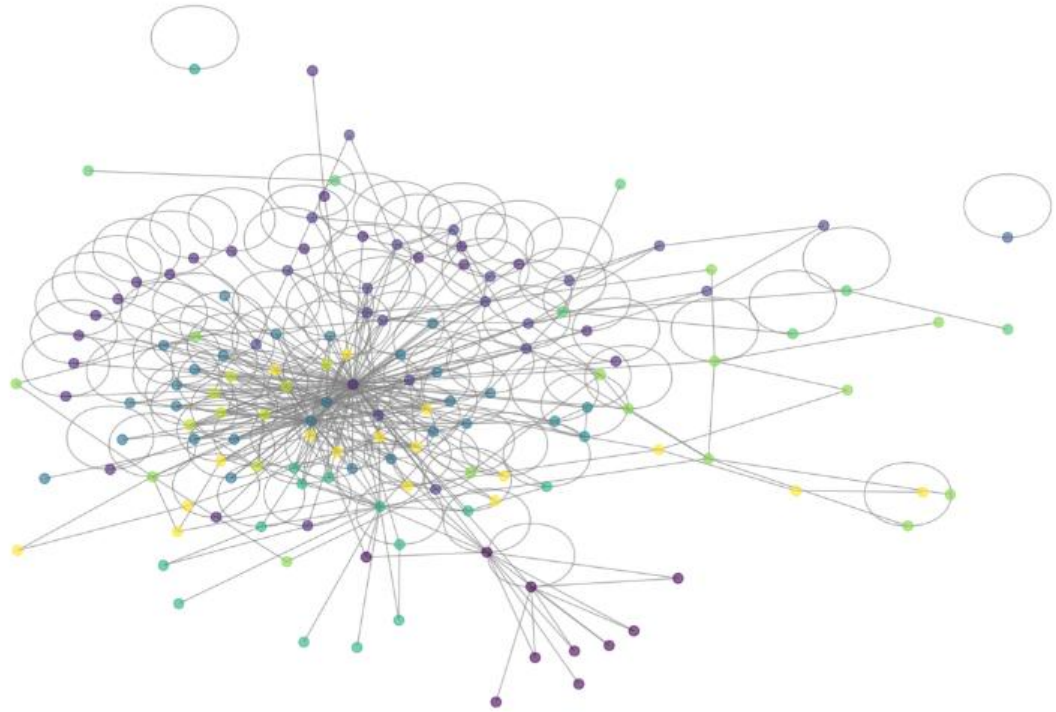


Figura 1 - Comunidades Louvain

Fonte: Dados originais da pesquisa

Análise Quantitativa e Estrutural das Comunidades Detectadas pelo Algoritmo de Louvain.

A tabela 2, apresentou as características quantitativas dos subgrupos que foram identificados pelo algoritmo de Louvain, incluindo o número de nós, as arestas internas e externas para cada comunidade.

Observou-se uma significativa heterogeneidade no tamanho das comunidades, variando de grupos isolados compostos por um único nó, como as comunidades 6 e 3, até grupos extensos, com até 25 nós, como a comunidade 4. Esta variação indicou que a rede possuiu uma estrutura modular complexa, composta tanto por pequenas unidades quanto por grandes clusters de alta densidade.

As comunidades menores apresentaram geralmente um número reduzido de arestas internas, algumas contendo laços internos, conforme evidenciado pela presença de arestas internas em comunidades com apenas um nó. Por outro lado, as comunidades maiores, como a Comunidade 4, exibiram elevado número de arestas internas (62), porém mantiveram um número considerável de arestas externas (72), sugerindo que estes grupos tiveram uma interação substancial com outras partes da rede, atuando possivelmente como pontes ou hubs facilitadores de comunicação intercomunitária.

Comunidades intermediárias, tais como as comunidades 7 e 11, demonstraram equilíbrio entre conexões internas e externas, o que indicou a existência de grupos coesos, porém integrados funcionalmente ao restante da rede por meio de conexões relevantes.

Essa análise quantitativa corroborou a visualização gráfica apresentada na figura 3, onde as comunidades maiores corresponderam a núcleos densamente conectados e coloridos, enquanto os pequenos grupos ou nós isolados apareceram como perifericamente e com menor concentração de conexões internas. A coexistência de múltiplos hubs e a presença de arestas que interligaram diferentes comunidades reforçam a complexidade e a diversidade funcional da rede analisada.

Tabela 2. Análise das comunidades Louvain

Comunidade	Número de nós	Arestas Internas	Arestas Externas
Comunidade 6	1	1	0
Comunidade 3	1	1	0
Comunidade 5	3	6	4
Comunidade 8	7	9	2
Comunidade 10	8	16	24
Comunidade 0	10	15	7
Comunidade 7	13	21	22
Comunidade 9	14	19	16
Comunidade 11	17	27	29
Comunidade 2	20	46	34
Comunidade 1	23	42	68
Comunidade 4	25	62	72

Fonte: Resultados originais da pesquisa

Identificação dos Hubs de liderança

Em redes complexas, um hub é um nó que possui um grau de conexão significativamente maior que a média dos demais nós, funcionando como um ponto central ou de alta influência dentro da estrutura da rede. A identificação desses hubs é fundamental para compreender a dinâmica e a organização das comunidades detectadas, uma vez que esses nós podem atuar como facilitadores da comunicação, pontos críticos para a robustez da rede ou, ainda, como vulnerabilidades potenciais.

O processo de identificação do hub em cada comunidade pode ser formalizado da seguinte maneira:

Seja $C_k \subseteq V$ a comunidade i composta por um conjunto de nós. O hub h_i da comunidade foi definido como o nó com maior grau dentro de C_k conforme a eq. (10):

$$h_k = \arg\max_{v \in C_k} \deg(v) \qquad (10)$$

em que deg(v) representa o grau do nó v.

A tabela 3 na coluna "Grau do Hub" revelou os nós mais influentes de cada grupo.

O Super Hub, representado através da figura 4, mostrou que o nó FFXS07200006VM (Comunidade 4) teve o maior grau (27). Este é um ponto crítico de falha ou um influenciador principal. Se este nó fosse removido, a estabilidade da maior comunidade da rede seria severamente impactada.

Na comunidade 0 representada através da figura 5, o hub tem grau 9 para uma comunidade de 10 nós. Isso significou que esse hub estava conectado a praticamente todos os outros membros do seu grupo, configurando uma topologia em estrela muito centralizada.

Tabela 3. Tabela de características da comunidade com o Grau do Hub

Comunidade	Número de Nós	Arestas Internas	Arestas Externas	Hub	Grau do Hub
Comunidade 7	1	1	0	FFXS07100013 MIG	2
Comunidade 10	1	1	0	FFXS00500001 QA	2
Comunidade 11	3	6	10	FFXL07100026 VM	4
Comunidade 5	5	10	10	FFXS07100106 VM	5
Comunidade 9	7	9	2	FFXS07100102	6

Comunidade 12	10	14	19	FFXS07500003 VM	6
Comunidade 0	10	15	7	FFXL07100022 VM	9
Comunidade 3	11	17	20	FFXS07100066 VM	5
Comunidade 8	13	21	22	FFXS00300001 VM	12
Comunidade 6	15	36	33	FFXS07500001 VM	10
Comunidade 2	15	21	15	FFXS07100004	5
Comunidade 1	23	42	68	FFXS07100086 VM	21
Comunidade 4	28	72	72	FFXS07200006 VM	27

Fonte: Resultados originais da pesquisa

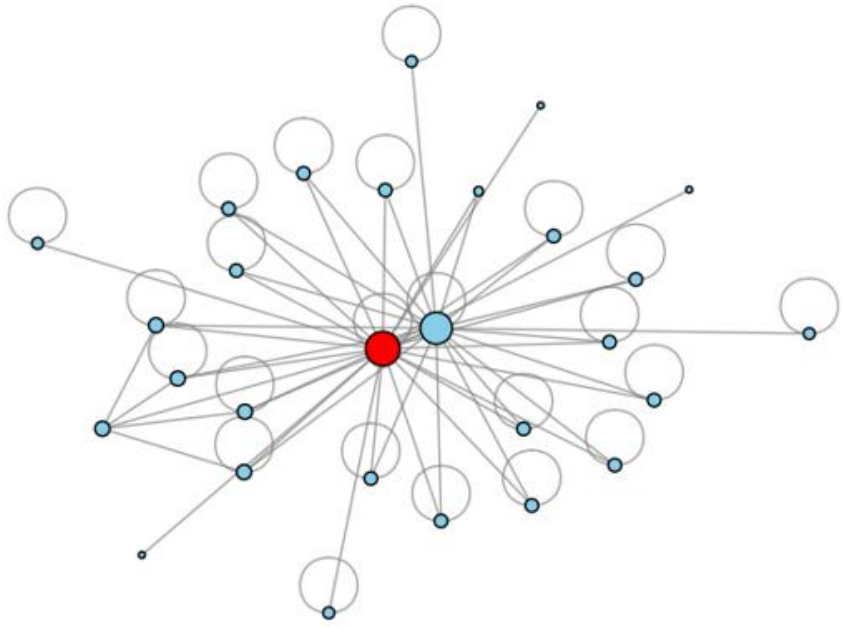


Figura 2 - Comunidade 4

Fonte: Dados originais da pesquisa

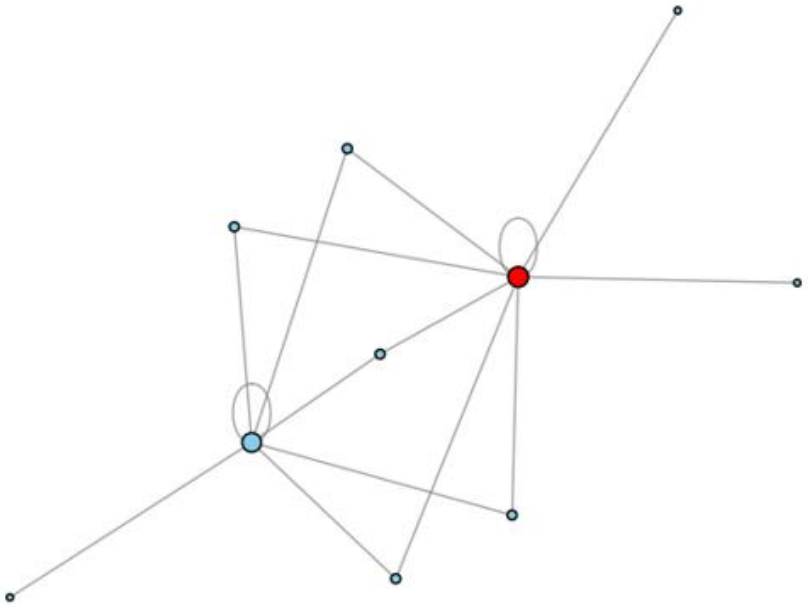


Figura 3 - Comunidade 0

Fonte: Dados originais da pesquisa

Centralidade de Intermediação das Arestas (Betweenness Centrality)

As pontes internas representam arestas cuja remoção poderia fragmentar a comunidade ou aumentar drasticamente a distância entre os nós. A tabela 4 contém as informações referentes as pontes internas ou centralidade de intermediação das arestas.

A centralidade de intermediação de um nó v é dada pela eq. (11):

$$g(v) = \sum_{s \neq v \neq t} \frac{\sigma_{st(v)}}{\sigma_{st}} \quad (11)$$

Em que:

σ_{st} é o número total de caminhos mais curtos do nó s até o nó t.

$\sigma_{st}(v)$ é o número desses caminhos mais curtos que passam pelo nó v.

É importante frisar que a tabela 4 apresentou as **"**Pontes Internas", que são arestas com alta Centralidade de Intermediação de Arestas (Edge Betweenness).

Perfil de Alta Fragilidade (Dependência de Pontes)

Neste grupo, a estrutura é "esticada". O hub tem muitos braços, mas não há conexões secundárias entre os membros.

Comunidade 1 representada na tabela 4 é o caso mais extremo, pois possuiu um hub potente (Grau 21) e 22 pontes internas. Isso indicou uma topologia em estrela quase pura, ou seja, se o hub ou suas conexões falhassem, a comunidade deixaria de existir como unidade funcional.

Em uma perspectiva operacional técnica para migração entre data centers, seja físico ou virtual a recomendação é que todos os servidores desta comunidade fossem migrados em uma única onda, evitando problemas de performance e indisponibilidade de sistemas.

Comunidade 8 representada através da tabela 4, possui 6 pontes para 7 nós. Quase toda aresta interna é um ponto crítico de ruptura.

Perfil de Alta Resiliência (Redundância de Caminhos)

Aqui, o hub é forte, mas a comunidade é tão bem conectada internamente que a intermediação de arestas é baixa.

Em uma perspectiva operacional técnica para migração entre data centers, seja físico ou virtual a recomendação é que todos os servidores desta comunidade fossem migrados em uma única onda, evitando problemas de performance e indisponibilidade de sistemas.

Comunidade 4 representada através da figura 6 e tabela 4 é a maior da rede (28 nós) com o hub mais forte (Grau 27). Surpreendentemente, tem apenas 3 pontes internas. Isso significa que a informação circula por múltiplos caminhos; ela é a comunidade mais robusta contra falhas.

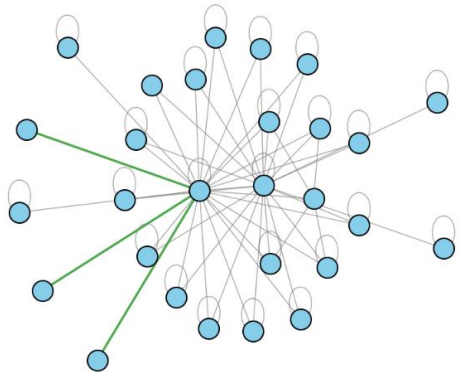


Figura 4. Comunidade 4

Fonte: Dados originais da pesquisa

Comunidade 2 representada através da figura 7 e tabela 4 possuiu 20 nós e apenas 4 pontes internas para 46 arestas internas. É um cluster altamente coeso onde a intermediação está diluída.

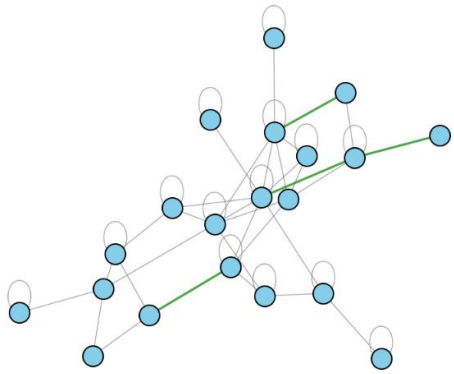


Figura 5. Comunidade 2

Fonte: Dados originais da pesquisa

Perfil de Transição e Fluxo Externo

Comunidades que equilibram a organização interna com a necessidade de conectar à rede global.

Comunidade 7 representada através da figura 8 e tabela 4 teve um hub de grau 12 para 13 nós e 5 pontes. É uma estrutura eficiente, mas o alto número de arestas externas (22) sugere que o hub também atuava como um porteiro para o resto da rede.

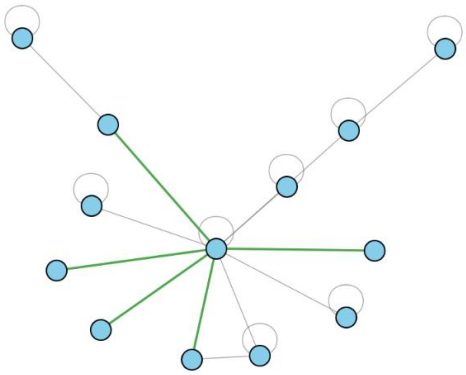


Figura 6. Comunidade 7

Fonte: Dados originais da pesquisa

Comunidade 3 representada através da figura 9 e tabela 4, apresentou 4 pontes e 20 arestas externas, este grupo funcionou como um "corredor". O hub (Grau 5) é relativamente fraco para o tamanho do grupo (11 nós), indicando uma liderança descentralizada.

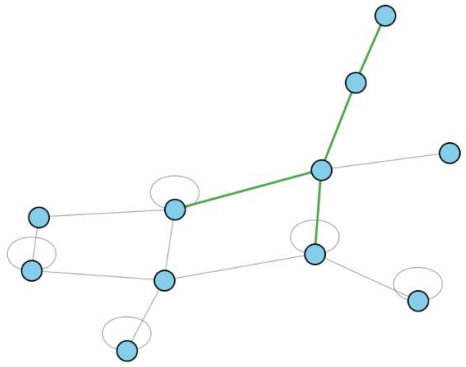


Figura 7. Comunidade 3

Fonte: Dados originais da pesquisa

Comunidade 9 representada através da figura 10 e tabela 4, similar à 3, possuiu 3 pontes e 16 arestas externas, mantendo um perfil de intermediação voltado para a integração da rede como um todo.

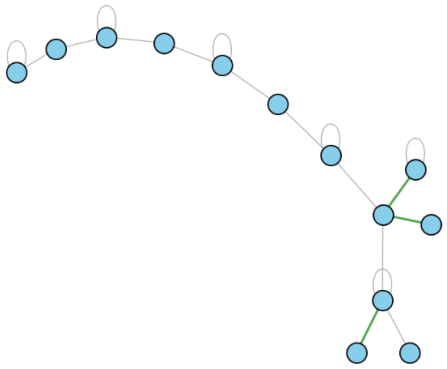


Figura 8. Comunidade 9

Fonte: Dados originais da pesquisa

Perfil de Pequenos Núcleos (Micro-Clusters)

Grupos menores onde a relação hub-intermediação é simplificada pela baixa escala.

Comunidade 0 representada através da figura 11 e tabela 4, mostrou uma topologia eficiente com 2 pontes para 10 nós. O hub (Grau 9) controlava quase todo o grupo.

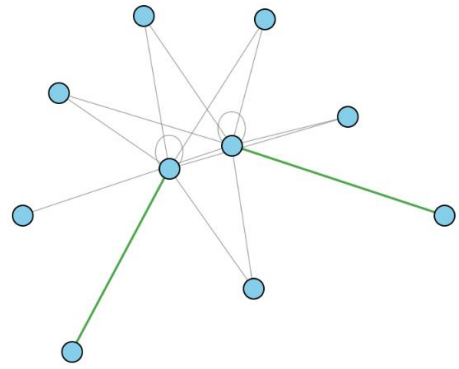


Figura 9. Comunidade 0

Fonte: Dados originais da pesquisa

Comunidade 11 representada através da figura 12 e tabela 4, possuiu 2 pontes para 7 nós. Estrutura moderadamente robusta.

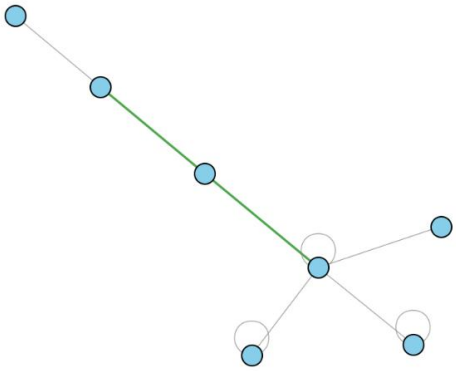


Figura 10. Comunidade 11

Fonte: Dados originais da pesquisa

Comunidade 5 e 10 representadas pelas figuras 13, 14 e tabela 4, possuíram zero pontes internas. Isso indicou que são "cliques" ou grupos onde todos estão conectados entre si de forma tão densa que nenhuma remoção de aresta única isola um nó.

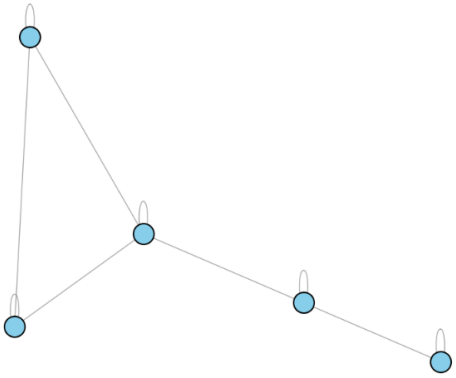


Figura 11. Comunidade 5

Fonte: Dados originais da pesquisa

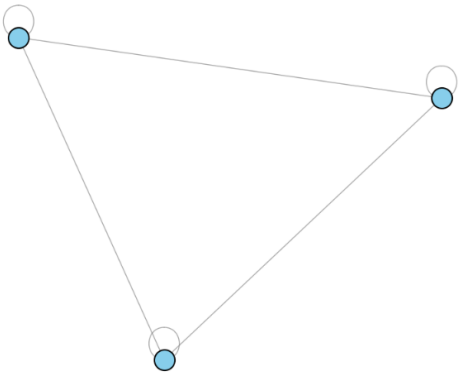


Figura 12. Comunidade 10

Fonte: Dados originais da pesquisa

Tabela 4. Análise das comunidades e métricas de centralidade ponte internas

Comunidade	Número de nós	Arestas Internas	Arestas Externas	Hub	Grau do Hub	Pontes Internas
Comunidade 10	3	6	10	FFXL0710 0026VM	4	0
Comunidade 5	5	10	10	FFXS0710 0106VM	5	0
Comunidade 11	7	9	13	FFXS0750 0003VM	6	2
Comunidade 8	7	9	2	FFXS0710 0102	6	6
Comunidade 0	10	15	7	FFXL0710 0022VM	9	2
Comunidade 3	11	17	20	FFXS0710 0066VM	5	4
Comunidade 7	13	21	22	FFXS0030 0001VM	12	5
Comunidade 9	13	18	16	FFXS0710 0004	5	3
Comunidade 2	20	46	34	FFXS0750 0001VM	10	4
Comunidade 1	23	42	68	FFXS0710 0086VM	21	22
Comunidade 4	28	72	72	FFXS0720 0006VM	27	3

Fonte: Dados originais da pesquisa

Resultado sobre a Análise da Centralidade de Intermediação, Pontes Internas e Grau do Hub no Contexto de Migração entre Data Centers

A análise conjunta da centralidade de intermediação das arestas, do número de pontes internas e do grau dos hubs forneceu uma visão aprofundada das dependências estruturais e

operacionais da rede, particularmente relevante em cenários de migração de servidores entre data centers. Essas métricas permitiram identificar comunidades com maior ou menor flexibilidade para migração, bem como potenciais riscos associados à fragmentação da conectividade e à interrupção de fluxos críticos.

No grafo analisado, foram identificadas 97 arestas classificadas como pontes, indicando uma rede com elevada dependência de conexões críticas, característica comum em infraestruturas distribuídas onde serviços e workloads mantêm relações funcionais entre diferentes domínios físicos ou lógicos.

Relação entre Grau do Hub e Dependência Operacional

Comunidades com hubs de alto grau tendem a concentrar grande volume de conexões, funcionando como pontos de agregação de serviços ou recursos. A Comunidade 4, por exemplo, apresentou o maior número de nós (28), elevado número de arestas internas (72) e externas (72), além de um hub com grau 27. Apesar dessa alta conectividade, observou-se um número relativamente baixo de pontes internas (3), sugerindo redundância estrutural significativa. Sob a perspectiva de migração, essa comunidade apresentou alta resiliência, sendo possível migrar subconjuntos de nós sem comprometer imediatamente a coesão funcional do grupo, desde que as conexões externas sejam preservadas.

Em contraste, a comunidade 1, com 23 nós e hub de grau 21, apresentou 22 pontes internas, evidenciando uma estrutura fortemente dependente de arestas críticas mesmo no interior da própria comunidade. Esse padrão indica acoplamento funcional elevado, no qual a migração de nós ou a redistribuição de workloads pode resultar em efeitos cascata, exigindo planejamento cuidadoso, migração coordenada ou introdução prévia de redundâncias.

Pontes Internas como Indicador de Fragilidade à Migração

O número de pontes internas é particularmente relevante para avaliar o impacto da migração inter–data center ou intra-comunidade. Comunidades como a comunidade 8, que apresentou apenas 7 nós, mas concentra 6 pontes internas, revelaram uma topologia altamente frágil. Nesse caso, a migração de um único nó ou a indisponibilidade temporária de uma aresta crítica pode fragmentar significativamente a comunidade, afetando serviços dependentes.

Situação semelhante foi observada nas comunidades 3, 7, que apresentaram número moderado de nós, mas mantiveram entre 4 e 5 pontes internas. Essas comunidades atuaram

como estruturas intermediárias, onde a migração poderia ser realizada de forma incremental e monitorada, evitando a desconexão de componentes interdependentes.

Por outro lado, comunidades como a comunidade 5 e a comunidade 10, apesar de possuírem conexões externas relevantes, não apresentaram pontes internas. Esse padrão sugere que, internamente, a conectividade é robusta e pouco dependente de arestas críticas, tornando a migração interna menos arriscada, desde que as dependências externas sejam adequadamente tratadas.

Considerando os insights citados foi criado uma análise para estabelecer o risco e a prioridade de migração das comunidades dividida em ondas de migração conforme tabela 5. Migração de data center, prioridade por onda de migração.

Tabela 5. Migração de data center, prioridade por onda de migração

Comunidade	Nós	Arestas Externas	Pontes Internas	Risco de Migração	Prioridade (Onda)
Comunidade 10	3	10	0	Muito Baixo	1ª (Onda Piloto)
Comunidade 5	5	10	0	Baixo	1ª (Onda Piloto)
Comunidade 8	7	2	6	Baixo (Isolamento alto)	2ª (Baixo Impacto)
Comunidade 0	10	7	2	Moderado	2ª (Baixo Impacto)
Comunidade 11	7	13	2	Moderado	3ª (Média Complexidade)
Comunidade 9	13	16	3	Moderado	3ª (Média Complexidade)
Comunidade 3	11	20	4	Alto	4ª (Alta Dependência)
Comunidade 7	13	22	5	Alto	4ª (Alta Dependência)
Comunidade 2	20	34	4	Crítico	5ª (Estrutural)
Comunidade 1	23	68	22	Crítico	5ª (Estrutural)
Comunidade 4	28	72	3	Crítico	5ª (Estrutural)

Fonte: Resultados originais da pesquisa

Análise Detalhada das Fases

Onda Piloto (Comunidades 10 e 5). Estas são as candidatas ideais para iniciar o projeto.

Motivo: Possuem o menor número de nós (3 e 5) e zero pontes internas. Isso significa que a estrutura de aplicação dentro delas é simples e fácil de validar após a movimentação.

Objetivo: Testar os links de replicação e os procedimentos de cutover.

2. Onda de Baixo Impacto (Comunidades 8 e 0). Destaque para a comunidade 8, apesar de ter 7 nós, ela possui apenas 2 arestas externas. Ela é quase uma "ilha", o que minimiza drasticamente o risco de indisponibilidade de outros serviços externos durante a sua migração. Comunidade 0 apresenta um equilíbrio entre tamanho (10 nós) e poucas conexões externas (7).

3. Onda de média complexidade (Comunidades 11 e 9). Aqui o volume de dados e o número de conexões externas começam a subir (13 a 16 arestas externas).

O planejamento deve focar no mapeamento dessas dependências externas para garantir que os serviços não "quebrem" ao perder comunicação temporária com as comunidades que ainda não foram migradas.

4. Onda de alta dependência (Comunidades 3 e 7). Estas comunidades têm um volume de arestas externas superior a 20.

Risco: Elas estão altamente integradas ao restante do data center. A migração provavelmente exigirá janelas de manutenção mais extensas e um plano de rollback muito bem estruturado.

5. Onda estrutural e crítica (Comunidades 2, 1 e 4). Estas devem ser as últimas a serem migradas.

Complexidade de hubs: Os hubs (FFXS07200006VM na comunidade 4) possuem um grau de conexão quase total com os nós internos.

Impacto de Rede: A comunidade 4 e a comunidade 1 somam juntas 140 arestas externas. Migrá-las exige que quase todo o restante do ecossistema já esteja estável no novo ambiente, ou que a latência entre os data centers seja mínima, devido ao altíssimo tráfego de saída.

Centralidade de Intermediação e Migração entre Data Centers Arestas Externas

Comunidades com grande número de arestas externas, como as comunidades 1, 4 e 2, desempenharam papel central na conectividade inter–data center. Nesses casos, a migração de seus hubs ou de nós adjacentes podem ser tratadas como uma operação crítica, idealmente precedida por replicação de serviços, balanceamento de carga ou reengenharia de dependências.

Esta visualização criou um grafo em um nível mais abstrato, onde cada nó representou uma comunidade (identificada pelo algoritmo de Louvain) e as arestas entre elas representaram as conexões externas. A espessura da aresta indicou a intensidade da conexão, ou seja, quantos nós de uma comunidade se conectaram a nós de outras comunidades.

Isso ajudou a entender como as diferentes comunidades interagiram entre si, revelando a estrutura macroscópica da rede.

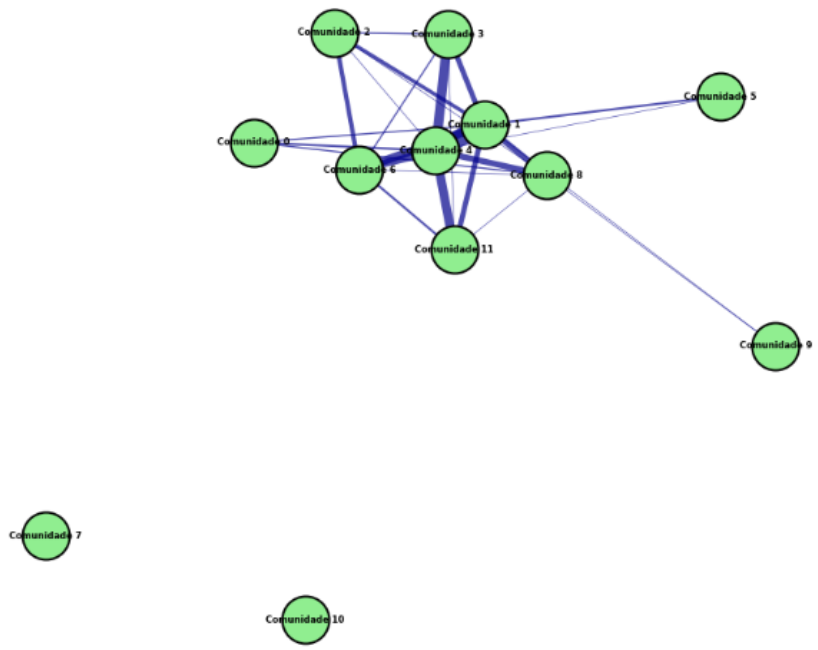


Figura 13. Conectividade entre comunidades

Fontes: Dados originais da pesquisa

Simulação do Mapeamento de Risco e o Impacto Operacional

Nesta seção foi realizado a simulação de remoção dos nós centrais (hub) das comunidades (Identificado pelo algoritmo de Louvain) na conectividade geral do grafo. Para isso foi calculado o número de componentes conectados e o tamanho do maior componente conectado no grafo resultante para entender o impacto da remoção.

Nesta análise, exploramos a estrutura de rede do ambiente de data center, onde cada nó representa um servidor e cada aresta, uma conexão (e.g., comunicação, dependência). As comunidades identificadas, através do algoritmo de Louvain, representaram agrupamentos naturais de servidores que interagiram mais entre si do que com o restante da rede. Essa segmentação foi crucial para entender o comportamento, as dependências e as vulnerabilidades do ambiente.

Tabela 6. Simulação de remoção de hub

Comunidade	Hub removido	Nós antes	Arestas antes	Nós após remoção	Arestas depois da remoção	Fragmentação	Quantidade de nós após a fragmentação

Comunidade 0	FFXL07100022VM	142	404	141	392	4	138
Comunidade 1	FFXS07100086VM	142	404	141	315	24	117
Comunidade 2	FFXS07500005VM	142	404	141	397	3	139
Comunidade 3	FFXS07100066VM	142	404	141	394	3	139
Comunidade 4	FFXS07200006VM	142	404	141	356	6	136
Comunidade 5	FFXS07100107VM	142	404	141	400	3	139
Comunidade 6	FFXS07500001VM	142	404	141	392	3	139
Comunidade 7	FFXS07100013MIG	142	404	141	403	2	140
Comunidade 8	FFXS00300001VM	142	404	141	384	6	136
Comunidade 9	FFXS07100102	142	404	141	397	7	133
Comunidade 11	FFXS07500007VM	142	404	141	394	3	139
Comunidade 10	FFXS00500001QA	142	404	141	403	2	140

Fonte: Resultados originais da pesquisa

Número de Interrupções ou Falhas

Mapeamento de Risco e Impacto Operacional: A identificação de hubs em cada comunidade e a simulação de sua remoção (ataques direcionados) forneceram evidências quantitativas do impacto operacional. A tabela de "Resultados da Simulação de Remoção de Hubs por Comunidade" e os gráficos de "Impacto da Remoção de Hubs" mostram diretamente quais comunidades e, por extensão, quais grupos de servidores são mais críticos. Por exemplo, a remoção do hub da Comunidade 1 (FFXS07100086VM) resultou em 24 componentes fragmentados, e uma queda significativa na quantidade de nós conectados (de 140 para 117). Isso quantifica o risco, ou seja, a falha desse único servidor resultaria em múltiplas interrupções, fragmentando a rede e isolando 21 servidores do core principal, conforme ilustrado através da figura 17:

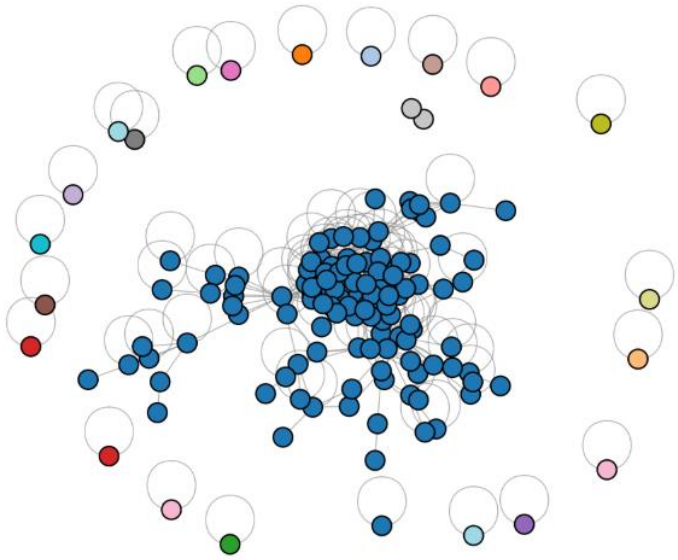


Figura 14. Grafo após remoção do nó hub FFXS07100086VM da comunidade 1

Modelo de Apoio a Migração

1. Fase de Mapeamento e Detecção de Comunidades:

O objetivo foi segmentar a rede em grupos naturais de servidores que interagiram intensamente entre si.

Foram utilizados algoritmos de detecção de comunidades (Louvain) para identificar esses agrupamentos. Visualizar as comunidades para entender sua estrutura e composição. As visualizações de comunidades coloridas demonstraram a capacidade de dividir a rede em subgrupos coesos.

2. Fase de Análise de Criticidade e Identificação de Hubs:

O objetivo foi Identificar os servidores mais críticos dentro de cada comunidade e na rede como um todo, através do cálculo de métricas de centralidade (Grau, intermediação, proximidade) para os nós de cada subgrafo comunitário, o foco foi encontrar nós que atuaram como pontes essenciais e na centralidade de grau para identificação de nós com diversas conexões.

3. Fase de Análise de Robustez e Simulação de Falhas:

O objetivo foi avaliar a vulnerabilidade da rede a falhas direcionadas ou aleatórias, isso possibilitou a quantificação do impacto operacional, através da remoção de nó crítico (Hubs) e de nós aleatórios o que ajudou a entender a fragmentação dos componentes.

4. Fase de Planejamento Otimizado (Migrações, Segurança, Resiliência):

O objetivo foi transformar os insights da SNA em planos estratégicos para operações e segurança das migrações dos servidores do data center, identificação de SPOFs (Single

point of failures), e a quantificação do impacto (Fragmentação e quantidade de nós após a fragmentação), isto ajudou a priorizar a proteção dos ativos mais críticos.

Benefícios Chave da Metodologia

Evidência Quantitativa: Passa de uma gestão baseada em intuição para uma gestão orientada por dados, com métricas claras de desempenho e risco.

Redução de Interrupções: Identifica proativamente pontos de falha, permitindo mitigações antes que incidentes ocorram.

Planejamento Eficiente: Acelera o planejamento de migrações e mudanças, minimizando surpresas e retrabalho.

Aumento da Resiliência: Fortalece a rede contra-ataques e falhas, garantindo maior disponibilidade de serviços.

Insights Acionáveis: Fornece uma compreensão profunda da estrutura da rede, permitindo decisões informadas sobre arquitetura, segurança e alocação de recursos.

Conclusões

A aplicação da Análise de Redes Sociais (SNA) no contexto de data centers demonstrou ser uma abordagem eficaz para a compreensão estrutural e operacional de ambientes complexos. Por meio da modelagem da rede, em que nós representaram servidores e arestas representaram conexões ou dependências, foi possível identificar comunidades utilizando o algoritmo de Louvain, evidenciando agrupamentos naturais de interação entre servidores.

Os resultados obtidos forneceram evidências quantitativas relevantes para o mapeamento de riscos e impactos operacionais, especialmente a partir da identificação de hubs, pontes e da simulação de falhas. Essa análise possibilitou a priorização de ações, a redução de riscos em processos de migração e a otimização na alocação de recursos, contribuindo para maior eficiência no planejamento.

Além disso, a identificação de pontos críticos, como nós com alta centralidade e potenciais pontos de falha, reforçou a importância da abordagem para o aumento da segurança e resiliência da infraestrutura. A utilização de métricas estruturais, como densidade, grau e dependências, permitiu classificar comunidades em níveis de prioridade e risco, apoiando a tomada de decisão estratégica.

Por fim, como continuidade do trabalho, propõe-se a aplicação de outros métodos, como o Spectral Clustering e uma validação prática comparando as sugestões de migração

do método com cenários reais passados, visando comparar abordagens e aprimorar a precisão das análises em diferentes cenários.

Agradecimento

Agradeço, primeiramente, a Deus, à minha esposa, Kátia; e aos meus filhos, Isaque e Pedro, pelo apoio, compreensão, resiliência.

Referências

BORGATTI, S. P.; EVERETT, M. G.; JOHNSON, J. C. Analyzing Social Networks. 2. ed. London: SAGE Publications, 2018.

KNOKE, David; YANG, Song. Social Network Analysis. 3. ed. Thousand Oaks: SAGE Publications, 2008.

DI PIETRO, Antonio; CAVEDON, Francesco; ROSATO, Vittorio; STERGIOPOULOS, George. Modeling Networks of Interdependent Infrastructure in Complex Urban

Environments Using Open-Data. Scitepress – Proceedings of the (…). 2024
ROY, Arjun; ZENG, Hongyi; BAGGA, Jasmeet; PORTER, George; SNOEREN, Alex C.

Inside the Social Network's (Datacenter) Network. Proceedings of the 2015 ACM SIGCOMM, 2015.

Apêndices

Apêndice 1 - Arquivo "tcc_script_python.py", contendo Código com o algoritmo de machine learning.



tcc_script_python.py

Apêndice 2 – Arquivo Excel "pcluster.xlsx" contendo a base de dados utilizada para o treinamento do modelo.



pcluster.xlsx